# 大模型推理系统项目报告

### 一. 基础功能:

### 故事续写:

命令行直接显示续写结果。

### AI 对话:

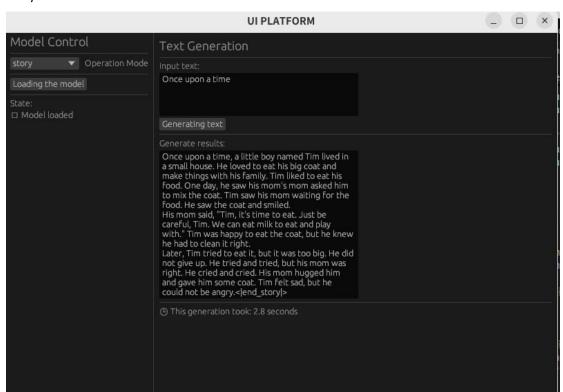
```
进入对话模式(输入exi进出):
how is the weather?
start generate_chat
go to generate_cache
finish ge
```

### 二. 优化及扩展

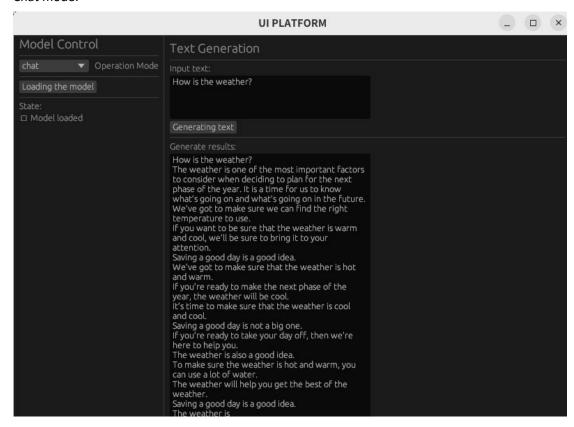
## 1. 可交互 UI

使用 egui 库实现,可以选择 chat/story 模式,添加了加载模型按钮,分别加载 chat 或 story 模型。用户在右侧输入文本,按 Generating text 按钮,输出对应的回复文本。 在底部添加记录耗时的模块,方便比较各种优化方法的效果。

#### Story mode:

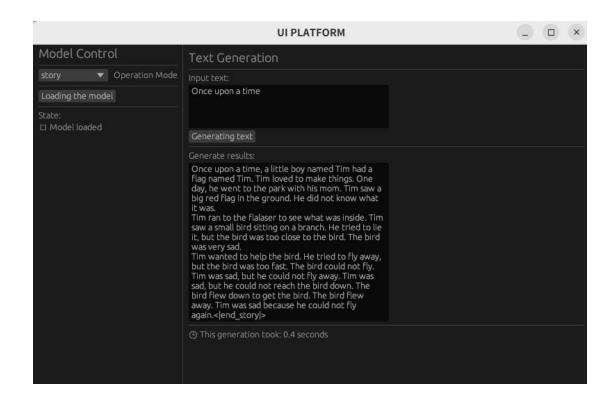


#### Chat mode:



# 2. SMID 加速矩阵乘算子

使用 AVX 指令集,做 256 位向量操作,一次处理 8 个 f32 数据,可以充分提高计算吞吐量。测试 story 模式下,输入同样的文本,生成回复耗时较没有优化时,有了较大的减少。由原来的 2.8s 缩减为 0.4s。



## 三. 未来优化方向

时间有些不够了,可以做的还有很多,目前正在进行中的有:

混合精度推理;

多会话管理以及历史会话回滚;

CUDA 加速计算